

Introducción: data statements para datasets

Sabemos que los datos juegan un papel fundamental en el aprendizaje automático. Cada modelo de aprendizaje automático se entrena y evalúa utilizando datos. Las características de estos conjuntos de datos (en inglés, *datasets*) cambiarán completamente el comportamiento de un modelo. Es poco probable que un modelo funcione bien si su contexto de uso no coincide con sus datasets de entrenamiento o evaluación, o si estos datasets reflejan **sesgos no deseados**.

Los data statements para datasets son una metodología que permiten caracterizar los datos y hacer explícitos posibles riesgos de su uso. Tienen el potencial de aumentar la **transparencia** y la **responsabilidad** de los *productos* basados en esos datos. Si tenemos un data statement nos podemos preguntar si un sistema entrenado en ese dataset es o no apropiado para cómo se planea utilizar el sistema. Un data statement ayuda también a mejorar la **reproducibilidad** de un modelo al documentar cómo difieren distintas versiones del mismo dataset.

Están destinados a abordar las necesidades de dos grupos de partes interesadas clave: creadores de datasets y consumidores de datasets. Para los **creadores** de datasets, el objetivo principal es fomentar una reflexión cuidadosa sobre el proceso de creación, distribución y mantenimiento de un conjunto de datos, incluidas las suposiciones subyacentes, los riesgos o daños potenciales y las implicaciones del uso. Para los **consumidores** de datasets, el objetivo principal es garantizar que tengan la información que necesitan para tomar decisiones informadas sobre el uso de un conjunto de datos.

La forma de elaborar un data statement consiste en entrevistar al creador o responsable del dataset y realizar la serie de preguntas que se enumeran en este documento. En la siguiente sección se detallan los pasos a seguir.

Pasos a seguir

El objetivo es elaborar un data statement para el dataset de otra mentoría de la diplomatura. Se requerirá la colaboración de un estudiante de la mentoría que usó el dataset en cuestión, al que llamaremos **experto del dataset**. Se recomienda hacer el data statement en grupos de 2 o 3 personas.

En primer lugar, hacer una copia de este documento, cambiar su nombre para reflejar el número de grupo, y usarlo como guía en una **reunión sincrónica** entre el grupo y el experto del dominio. En esta reunión el grupo entrevistará al experto usando las preguntas de las siguientes secciones. Este formulario para data statements tiene 15 preguntas obligatorias y 8 metadata obligatorias del data statement marcados con **COMPLETAR**. Si la información de alguno de estos ítems no está disponible, solicitamos explicar por qué (por ejemplo, el experto no lo sabe, o esta información es confidencial). Se recomienda una reunión de una hora y media o dos horas de duración. El grupo completará el documento con las respuestas a las preguntas y lo compartirá con el experto del dataset. El experto

leerá el borrador y realizará sugerencias que serán revisadas y resueltas por el grupo original. El resumen del data statement que es parte de la metadata debe ser completado después de contestar las preguntas resaltando los aspectos considerados más importantes.

No todas las preguntas serán aplicables a todos los datasets. Los data statements varían según el dominio de aplicación. Por ejemplo, [Bender y Friedman](#) describen una propuesta para datasets que contienen información sobre **personas**. Estas preguntas están diferenciadas en las siguientes secciones y pueden ser omitidas para datasets que no involucren personas. Este documento se basa en las metodologías de Bender y Friedman y de [Timnit Gebru et al.](#)

Esta introducción se debe eliminar al momento de la entrega. La entrega del documento final no debe superar las 6 páginas incluyendo las preguntas de la plantilla. La plantilla no debe ser modificada (ni sus márgenes, ni su tipo de letra, etc). No se deben borrar las preguntas sino que se deben contestar cuando corresponda.

Plantilla a completar

Metadatos

Nombre del dataset (si tiene nombre, si no asignarle uno): **COMPLETAR**

Fuente (incluir link a la fuente si está disponible y describirla): **COMPLETAR**

Experto del dataset: **COMPLETAR**

Autores del data statement: **COMPLETAR**

Otros que contribuyeron a este documento: **COMPLETAR**

Versión (si está disponible) y fecha aproximada de creación: **COMPLETAR**

Licencia bajo la que se distribuye el dataset: **COMPLETAR**

Resumen del data statement (largo mínimo 50 palabras y máximo 70 palabras):

COMPLETAR

1. Motivación para la creación del dataset

Las preguntas de esta sección están destinadas principalmente a alentar a los creadores de datasets a articular claramente sus razones para crear el conjunto de datos y promover la transparencia sobre los intereses de financiación.

1.1 ¿Con qué propósito se creó el conjunto de datos? ¿Se tenía como objetivo una tarea específica?

COMPLETAR

1.2 ¿Quién creó el conjunto de datos?

COMPLETAR

1.3 ¿Quién financió la creación del conjunto de datos?

COMPLETAR

2. Composición del dataset

Estas preguntas están destinadas a proporcionar a los consumidores del conjunto de datos la información que necesitan para tomar decisiones informadas sobre el uso del conjunto de datos para tareas específicas.

2.1 ¿Qué representan las instancias que componen el conjunto de datos (por ejemplo, documentos, fotos, personas, países, preguntas y respuestas, conversaciones)? ¿Hay varios tipos de instancias (por ejemplo, películas, usuarios y calificaciones; personas e interacciones entre ellas; nodos y conexiones)? Proporcione una descripción.

COMPLETAR

2.2 ¿Cuántas instancias hay en total (y de cada tipo, si corresponde)?

COMPLETAR

2.3 ¿De qué tipo de datos consta cada instancia? ¿Datos "sin procesar" (por ejemplo, texto o imágenes sin procesar) o datos estructurados? En cualquier caso, proporcione una descripción y algunos ejemplos.

COMPLETAR

2.4 ¿Hay anotaciones asociadas con cada instancia? Una anotación es información agregada a posteriori por otras personas sobre los datos, personas que no provienen de la muestra inicial (por ejemplo, palabras clave asociadas a fotos, traducciones a otros idiomas, transcripciones). Si es así, proporcione una descripción.

COMPLETAR

2.5 ¿Cree que hay algún aspecto de los datos que no ha sido representado y que podría llegar a resultar relevante para alguna aplicación o por sus efectos en algún segmento de la población (p. ej., falta información de género)? De ser así, proporcione una descripción.

COMPLETAR

2.6 ¿El conjunto de datos contiene datos que podrían considerarse confidenciales (por ejemplo, datos que están protegidos por privilegios legales o por la confidencialidad del médico-paciente, datos que incluyen el contenido de las comunicaciones no públicas de las personas)? Si es así, proporcione una descripción.

COMPLETAR

3. Recopilación del dataset

Estas preguntas están destinadas a identificar características de la recopilación del dataset para advertir a consumidores del conjunto de datos sobre posibles sesgos emergentes debido a decisiones de recolección.

3.1 ¿Qué mecanismos se utilizaron para recopilar los datos, elegir la muestra y curar los datos (por ejemplo, aparatos o sensores de hardware, curación humana manual o automática, programa de software)? Esta pregunta es particularmente importante para datasets que son demasiado grandes para ser inspeccionados a mano. Explicar la racionalidad de la muestra puede ayudar a los usuarios de datasets a entender a qué tipos de usos el dataset puede generalizar bien o mal.

COMPLETAR

3.2 ¿Quiénes participaron en el proceso de recopilación de datos (p. Ej., Estudiantes, trabajadores digitales, contratistas) y cómo se les compensó (p. Ej., ¿Cuánto se les pagó a los trabajadores)?

COMPLETAR

3.3 ¿Durante qué período de tiempo se recopilaron los datos?

COMPLETAR

3.4 ¿El conjunto de datos se relaciona con las personas? De lo contrario, puede omitir las preguntas de la sección 4.

COMPLETAR

4. Datos de personas

4.1 ¿Es posible identificar individuos (es decir, una o más personas físicas), ya sea directa o indirectamente (es decir, en combinación con otros datos) del conjunto de datos? Si es así, describa cómo.

4.2 ¿El conjunto de datos contiene datos que podrían considerarse sensibles de alguna manera, porque podrían producir efectos discriminatorios a algún grupo de población (por ejemplo, datos que caracterizan orígenes raciales o étnicos, orientaciones sexuales, creencias religiosas, género, edad, estatura, nivel de estudios, nivel de ingresos, lugar de residencia, lugar de origen, estatus migratorio, estado civil,)?

4.3 ¿Se notificó a las personas en cuestión sobre la recopilación de datos? Si es así, describa cómo se envió la notificación.

5. Usos

Estas preguntas están destinadas a alentar a los usuarios del dataset a reflexionar sobre las tareas para las que el dataset debe y no debe usarse. Al resaltar explícitamente estas tareas, los consumidores de datasets pueden tomar decisiones mejor informadas, previniendo riesgos o daños potenciales.

5.1 ¿Para qué tareas creen que se puede usar este conjunto de datos? ¿Ya se ha utilizado el conjunto de datos para alguna tarea? Si es así, proporcione una descripción.

COMPLETAR

5.2 ¿Hay tareas para las que no se debería utilizar el conjunto de datos? Si es así, proporcione una descripción.

COMPLETAR

5.3. ¿Hay algún posible escenario de daño que se pueda describir en términos de grupos sociales (grupo privilegiado / grupo protegido) y tipo de error con potencial para producir daños (falsos positivos / falsos negativos / diferencia de oportunidad, etc.)? Si es así, descríbalos.

5.4 ¿Algún otro comentario?